

卷积分类算法实验

鲁继元 2023012278

github: <https://github.com/moshi1412/STL10.git>

1 实验目标

本实验以STL-10 图像数据集为数据集，围绕深度学习图像分类任务进行尝试。自主设计满足要求的卷积神经网络，完成数据划分、模型训练、验证与测试的全流程，学会使用损失曲线、准确率等指标对模型性能进行科学评估，并判断过拟合等训练问题。

2 模型设计

2.1 基础模型

在设计模型时，首先尝试简单4层的卷积+池化+ReLU函数、全局池化后展平，经过全连接层的基础模型架构进行训练，每轮进行测试，可视化的时候发现模型在50轮附近时就已经收敛，模型在验证集上的准确率为65%左右。

从基础模型中可以发现几个问题，第一个是模型收敛太快，第二是模型并没有提取出更多的特征信息，模型处于快速达到中等水平无法上升。而且当加入Batch Norm层后模型的验证集上的性能维持在67%左右，虽然模型性能上升，但是训练更快收敛了，不到30轮模型性能就已经不再上升，可以认为BN层依据数据平均值和方差进行记录处理，事实上是对模型的学习做了一个稳定化，原本为了适应数据的反复波动被避免，从而使得训练更加有效。以下是一些改进措施。




Figure 1: 模型100轮训练曲线对比：上图为基础模型，下图为添加了BN层的模型的loss和准确率的曲线，可以明显看到加入BN层会加速收敛，由于收敛过快，学习率仍较大，故后期准确率波动明显，逐渐变小

2.2 基础模型加入DropOut模块

针对模型收敛过快的问题，有几种策略，dropout可以防止模型过快拟合，网络每次都使用不同的子网络学习，神经元不敢过度依赖某几个特征，数据增强也可以让模型在小数据上学到更多的内容，数据增强会在之后分析。此次实验中在每一层卷积和线性层后加入dropout，当使用dropout方式后，模型的收敛大大减慢，200轮训练结束，验证集的性能并没有下降，平均性能在80%左右，可以验证到dropout可以防止过早过拟合。

2.3 调整每层内部实现

基础实现中使用ReLU和最大池化，在基础模型上可以尝试平均池化和GeLU、tanh激活

活函数。至于这些激活函数的区别，ReLU 计算公式为 $\text{ReLU}(x) = \max(0, x)$ ，计算简单;GeLU 为平滑激活函数，形式为

$$\text{GeLU}(x) = x \cdot \frac{1}{2} \left[1 + \text{erf} \left(\frac{x}{\sqrt{2}} \right) \right]$$
$$\text{erf}(x) = \frac{2}{\sqrt{\pi}} \int_0^x e^{-t^2} dt$$

而且GELU自带高斯平滑特性，能减少过拟合，小样本数据集上表现明显更稳，也可以避免负数区域梯度恒为0，更不容易出现“死神经元”。

sigmoid貌似更多出现在二分类的输出层，因此我选择tanh作为另一个尝试选项，公式为 $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$ ，会把卷积的输出映射到(-1,1),所以不能把每层的ReLU都替换了，显然(-1,1)相比ReLU会损失掉很多信息。

2.4 加深层数

针对模型提取特征能力不足的问题，最直观的思路就是加深层数，期望通过增加参数和感受野来增强性能，但事实上，将卷积增至6层后，训练结束时模型最高达到75%，说明加深卷积层数没有太大的作用。

2.5 使用残差连接

虽然模型层数不深，不会明显出现梯度消失等问题，但是使用残差块可以在一个模块中传递更多的信息，因此想尝试使用残差模块对模型结构更新,但是同时模型的参数增加后会导致时间增长，我在实践中将上述的4层卷积层替换为残差模块，模块内部经过两层保持原大小的卷积之后与输出直接相加。

2.6 添加注意力模块

参考文献(1)中提到的一些针对分类的前沿模型内容，我在基础的代码版本上添加了注意力模块进行了简单的尝试，基于基础模型、BN层和dropout，在每层都添加注意力模块，分别使用SE模块和CBAM模块构建模型进行实验。

SE是对每个通道的特征图做全局平均池化，把 $H \times W \times C$ 的特征 α 压缩成 $1 \times 1 \times C$ 的向量,通过两层线性层之后再与 α 相乘。之所以这样设计，是为了让线性层尝试筛选 α 中需要重视的内容。

CBAM的逻辑类似，通过平均池化和最大池化捕捉 α 中更重要的信息所处的位置，从而能更好地抓住图像分类的依据。

添加SE模块的模型在验证集上的结果为75%左右，添加CBAM模块的模型在验证集只能达到70%，效果并不是很好。可以认为基础的卷积模型能力不足，就算加入了注意力机制，也没有充足的建模能力。

3 实验

3.1 实验配置

1. 表格1的实验在本机GPU上运行，最大学习率为0.001，选取模型为验证集上的准确率最高的模型，训练epoch为200轮，使用AdamW优化器和余弦退火调度，batch size为8，优化模块内dropout率为0.2，loss使用交叉熵损失。由于各类别均为700个样本，实验各类别使用相同的权重，无需手动调整权重。实验中的测试模型为200轮中验证集上平均准确率最高的模型，部分模型到达200轮时准确率仍在缓慢上升(如图2所示)
2. 添加模块的模型都沿用了ReLU、Batch Normalization和dropout。替换池化和替换非线性函数为GeLU时,都是把四层的卷积后的ReLU和线性层之间的ReLU全部替换；替换为tanh时只将2，3层替换，并且继续沿用Batch Normalization和dropout。

3.2 数据增强

在性能最优的模型上使用数据增强，由于图片分辨率为 96×96 ,图片较小，信息原本较小，不能再损失信息，无法使用裁剪和缩放，而且大幅度的旋转也有可能導致物体超出画面，因此在数据增强中使用归一化、随机翻转、 8° 的随机旋转和亮度、对比度等为0.1的颜色增强处理。实验中可以发现，添加了数据增强后会导致时间大幅增加，并且直到130轮左右loss下降才较为平缓，200轮训练完模型验证集性能仍在上升，可以认为数据增强改变了数据分布，让模型更难抓住数据内的特征，延长训练时间，增加至240轮时，模型达到在80%左右，之后开始过拟合，可以认为数据增强可以提高模型的泛化性。




Figure 2: 从左到右、从上到下分别为残差、SE、CBAM、加深层数的模型曲线，验证集准确率仍在缓慢上升

3.3 模型实验结果

各个模型的实验结果如表格1，可以当作各个模块和做法的消融实验，可以表现出各个模块对性能的影响，表格中的模型和处理参考第2节。

3.4 超参调整

除去优化器、调度器和数据增强的参数，实验可调整的超参为学习率、Batch Size、Epoch，选取性能最好的加入残差模块并进行数据增强开展实验。表格3训练轮次为200轮。虽然有scheduler会调控学习率，初始学习率的大小还是会影响整体的训练进程。受设备限制，只尝试batch size至32。由于epoch本身的影响可以从训练曲线看到，在模型收敛时延长epoch没有意义，故没有做epoch的实验。

Table 1: STL-10测试集上的分类指标对比

模型/指标	指标	飞机	汽车	鸟	猫	鹿	狗	猴子	马	船	卡车	平均
CNN	Precision	0.7870	0.7391	0.6625	0.5089	0.6139	0.4138	0.5600	0.7073	0.8605	0.7300	0.6583
	Recall	0.8500	0.8500	0.5300	0.5700	0.6200	0.4800	0.5600	0.5800	0.7400	0.7300	0.6510
	F1-score	0.8173	0.7907	0.5889	0.5377	0.6169	0.4444	0.5600	0.6374	0.7957	0.7300	0.6519
	Acc	0.6911	0.6538	0.4173	0.3677	0.4460	0.2857	0.3889	0.4677	0.6607	0.5748	0.4954
CNN+BN	Precision	0.6961	0.8413	0.4000	0.7333	0.5349	0.2708	0.4032	0.4632	0.5877	0.4425	0.5373
	Recall	0.7100	0.5300	0.7400	0.2200	0.4600	0.1300	0.2500	0.6300	0.6700	0.7700	0.5110
	F1-score	0.7030	0.6503	0.5193	0.3385	0.4946	0.1757	0.3086	0.5339	0.6262	0.5620	0.4912
	Acc	0.5420	0.4818	0.3507	0.2037	0.3286	0.0963	0.1825	0.3642	0.4558	0.3909	0.3396
CNN+BN+DR	Precision	0.8367	0.8283	0.6429	0.5385	0.6465	0.4881	0.5929	0.7048	0.8488	0.8119	0.6939
	Recall	0.8200	0.8200	0.6300	0.6300	0.6400	0.4100	0.6700	0.7400	0.7300	0.8200	0.6910
	F1-score	0.8283	0.8241	0.6364	0.5806	0.6432	0.4456	0.6291	0.7219	0.7849	0.8159	0.6910
	Acc	0.7069	0.7009	0.4667	0.4091	0.4741	0.2867	0.4589	0.5649	0.6460	0.6891	0.5403
CNN Deeper	Precision	0.8557	0.8500	0.5798	0.5524	0.6937	0.5053	0.6283	0.8611	0.8416	0.8966	0.7264
	Recall	0.8300	0.8500	0.6900	0.5800	0.7700	0.4800	0.7100	0.6200	0.8500	0.7800	0.7160
	F1-score	0.8426	0.8500	0.6301	0.5658	0.7299	0.4923	0.6667	0.7209	0.8458	0.8342	0.7178
	Acc	0.7281	0.7391	0.4600	0.3946	0.5746	0.3265	0.5000	0.5636	0.7328	0.7156	0.5735
CNN+Res	Precision	0.9462	0.8660	0.7570	0.7857	0.7477	0.6333	0.6870	0.8370	0.8854	0.8381	0.7983
	Recall	0.8800	0.8400	0.8100	0.7700	0.8000	0.5700	0.7900	0.7700	0.8500	0.8800	0.7960
	F1-score	0.9119	0.8528	0.7826	0.7778	0.7729	0.6000	0.7349	0.8021	0.8673	0.8585	0.7961
	Acc	0.8381	0.7434	0.6429	0.6364	0.6299	0.4286	0.5809	0.6696	0.7658	0.7521	0.6688
CNN+SE	Precision	0.9158	0.8700	0.6559	0.6629	0.6881	0.4622	0.6408	0.7802	0.9278	0.8558	0.7459
	Recall	0.8700	0.8700	0.6100	0.5900	0.7500	0.5500	0.6600	0.7100	0.9000	0.8900	0.7400
	F1-score	0.8923	0.8700	0.6321	0.6243	0.7177	0.5023	0.6502	0.7435	0.9137	0.8725	0.7419
	Acc	0.8056	0.7699	0.4621	0.4538	0.5597	0.3354	0.4818	0.5917	0.8411	0.7739	0.6075
CNN+CBAM	Precision	0.8000	0.8202	0.5810	0.4860	0.7375	0.4737	0.5780	0.6355	0.8090	0.7018	0.6623
	Recall	0.8400	0.7300	0.6100	0.5200	0.5900	0.4500	0.6300	0.6800	0.7200	0.8000	0.6570
	F1-score	0.8195	0.7725	0.5951	0.5024	0.6556	0.4615	0.6029	0.6570	0.7619	0.7477	0.6576
	Acc	0.6942	0.6293	0.4236	0.3355	0.4876	0.3000	0.4315	0.4892	0.6154	0.5970	0.5003

图中各类别中准确率最高者已加粗，各模型中平均性能最高者也已加粗。

Table 2: STL-10测试集上的分类指标对比

优化/指标	指标	飞机	汽车	鸟	猫	鹿	狗	猴子	马	船	卡车	平均
GeLU替换	Precision	0.7843	0.8100	0.6207	0.5351	0.6905	0.5652	0.6117	0.6455	0.7957	0.7431	0.6802
	Recall	0.8000	0.8100	0.7200	0.6100	0.5800	0.3900	0.6300	0.7100	0.7400	0.8100	0.6800
	F1-score	0.7921	0.8100	0.6667	0.5701	0.6304	0.4615	0.6207	0.6762	0.7668	0.7751	0.6770
	Acc	0.6557	0.6807	0.5000	0.3987	0.4603	0.3000	0.4500	0.5108	0.6218	0.6328	0.5211 ↑
tanh替换	Precision	0.7963	0.7706	0.6813	0.5429	0.7363	0.5196	0.6182	0.6952	0.8929	0.8105	0.7064
	Recall	0.8600	0.8400	0.6200	0.5700	0.6700	0.5300	0.6800	0.7300	0.7500	0.7700	0.7020
	F1-score	0.8269	0.8038	0.6492	0.5561	0.7016	0.5247	0.6476	0.7122	0.8152	0.7897	0.7027
	Acc	0.7049	0.6720	0.4806	0.3851	0.5403	0.3557	0.4789	0.5530	0.6881	0.6525	0.5511 ↑
平均池化	Precision	0.8137	0.8421	0.6857	0.6019	0.6216	0.5556	0.6250	0.7374	0.8554	0.6847	0.7023
	Recall	0.8300	0.8000	0.7200	0.6500	0.6900	0.5000	0.6000	0.7300	0.7100	0.7600	0.6990
	F1-score	0.8218	0.8205	0.7024	0.6250	0.6540	0.5263	0.6122	0.7337	0.7760	0.7204	0.6992
	Acc	0.6975	0.6957	0.5414	0.4545	0.4859	0.3571	0.4412	0.5794	0.6339	0.5630	0.5450 ↑
CNN+aug	Precision	0.8144	0.9870	0.8657	0.5656	0.8718	0.3795	0.6381	0.8525	0.8165	0.7373	0.7528
	Recall	0.7900	0.7600	0.5800	0.6900	0.6800	0.6300	0.6700	0.5200	0.8900	0.8700	0.7080
	F1-score	0.8020	0.8588	0.6946	0.6216	0.7640	0.4737	0.6537	0.6460	0.8517	0.7982	0.7164
	Acc	0.6695	0.7525	0.5321	0.4510	0.6182	0.3103	0.4855	0.4771	0.7417	0.6641	0.5702 ↑
CNN+Res+aug	Precision	0.8800	0.8378	0.7320	0.7391	0.7778	0.4837	0.7531	0.7941	0.9744	0.8333	0.7805
	Recall	0.8800	0.9300	0.7100	0.6800	0.7000	0.7400	0.6100	0.8100	0.7600	0.8000	0.7620
	F1-score	0.8800	0.8815	0.7208	0.7083	0.7368	0.5850	0.6740	0.8020	0.8539	0.8163	0.7659
	Acc	0.7857	0.7881	0.5635	0.5484	0.5833	0.4134	0.5083	0.6694	0.7451	0.6897	0.6295 ↓

Table 3: 不同BatchSize 与训练学习率下模型准确率对比

BS	Acc	Lr				
			0.01	0.005	0.001	0.0005
8	56.75	56.23	62.95	63.46		
16	62.83	59.62	63.62	64.23		
32	59.44	55.59	62.37	62.62		

4 可视化

为直观探究卷积网络的特征学习与类别判别能力，采用Grad-CAM 热力图进行可视化分析。Grad-CAM 能够依据梯度信息定位模型分类决策所聚焦的关键区域，直观展示网络对目标主体的关注程度，可有效对比不同模型能否精准聚焦目标。图3和图4为各模型的可视化结果。




Figure 3: 图片从上到下从左到右依次为基础模型、加深模型的层数、加入残差、使用数组合增强的残差模块的热力图,类别均为猫

5 数据分析可视化分析

1. 实验的基础模型只有四层卷积和最后的线性层，模型本身并不大，建模能力有限，可以看到所有实验的准确率均不及70%。
2. 添加Batch Normalization层会加速模型的收敛，这对于简单模型来说会迅速进入过拟合状态，测试集的准确率下滑。




Figure 4: 左图为添加了se模块、右侧为添加了cbam模块的热力图,类别均为飞机

3. Dropout正则化机制能够有效抑制模型过拟合，通过随机失活神经元的方式拉长模型有效学习周期，显著提升模型泛化准确率。这一现象表明，引入Dropout后，模型不再单一拟合训练样本的表层信息，而是逐步学习并捕捉图像的有效特征。结合图3可视化结果可知，模型能够精准定位图像主体核心区域，但易受图像极值像素干扰，对亮度偏高或偏低的区域存在过度关注的情况；同时热力图激活范围更广，体现出模型具备活跃、全面的图像特征捕捉能力

4. 适度加深网络层数能够小幅提升模型整体性能。对比基础模型与深层模型的热力图可发现，网络加深后，热力图的有效激活区域面积收缩，边缘过渡更加平滑。该现象可从两方面解释：其一，实验数据集规模有限，无法提供充足、多样的特征信息，不足以支撑增多的网络参数完成有效学习，深层模型在小样本数据下易出现过拟合或学习无效的问题；其二，网络层数加深会扩大模型感受野，但同时会增加梯度反向传播的难度，制约模型的优化效果。

5. 从实验数据可以看到，将模型细节实现替换为GeLU、tanh、平均池化之后，准确率有所上升，但相差不大，可以认为是在误差范围内，在模型性能较差的情况下不同的激活函数区别不大，池化方式不会很大程度影响模型的学习能力。

6. 使用残差连接可以显著提高模型的准确率，可以认为模型本身捕捉的信息不足以建模分类的问题，而原图的丰富信息可以更好的提供分类的依据。从热力图中可以看出，最后一层的活跃神经元减少，捕捉到的面积收缩，但也更加精确（身体、头部），所以性能虽然有所提升，但效果有限。

7. 使用注意力模块不如残差模块，这意味着模型自身的能力不足以支撑注意力模块的有效训练，通过图4可以发现，两种注意机制事实上都是在尝试筛选应该关注的位

置，所以热区会是零散和多样的，这说明注意力模块内的选择方式还是在有效进行，但是在热区准确的情况下，类别还是会判错，也可以说明模型能力局限性。

8.超参数调优实验结果表明，适度降低学习率可细化模型参数更新幅度，有效提升模型准确率，从训练曲线也可以看到；适当增大批次大小（batch size）也能小幅优化模型性能。在学习率调度器重置步数与训练轮数固定的条件下，增大batch size会减少单轮训练的参数更新次数，加快整体训练节奏，因此也不能把batch size调过大，需要同时考虑与学习率的配合才能达到最优的效果。同时增大batch size可有效降低训练过程中损失值与准确率的波动跳变，让训练过程更加稳定。

从可视化的过程中，学习率降低的时候，收敛反而更加容易和迅速，可以认为0.01和0.005的学习率有些大，导致探索过程存在波动；在表格之外，我还尝试调整调度器的 $T_{max} \propto \Sigma T_{max} \cdot \frac{1}{n} \cdot \frac{1}{F/0.6150} \cdot \frac{1}{f' / \Psi \Theta}$

9. 数据增强会带来不同的影响，对基础模型来说，性能会有提升，说明基础模型在原数据上性能确实到达极限，数据增强可以帮助模型学习更广的分布；加了残差的模型在数据增强后，学习到的性质会受到数据增强噪声的影响，说明该数据本身没有办法支持该模型的训练。从图3中可以看到模型尝试捕捉更多的部位和信息，但是数据无法让模型充分训练，故性能一般。

6 其他

1. AI使用本实验使用AI为豆包和GLM-5，提供GELU具体的公式、注意力模块和可视化内容的实现。

2. 代码位于<https://github.com/moshi1412/STL10.git>，uv环境、源码使用方式、模型权重和可视化结果可在仓库查看。

参考文献

- [1] 张珂,冯晓晗,郭玉荣,苏昱坤,赵凯,赵振兵,马占宇,丁巧林.2021.图像分类的深度卷积神经网络模型综述.中国图象图形学报,26(10):2305-2325[DOI:10.11834/jig.200302]